SARIMA_v002

April 14, 2020

1 Erstellen einer Umsatzprognose unter Verwendung eines SARIMA-Modells

1.1 Grundlegende Einstellungen:

1.1.1 Import von Modulen

Zunächst müssen die notwendigen Module importiert werden, damit auf diese zugegriffen werden kann.

```
[1]: #----------------
     # Web-Scraping
     from urllib.request import urlopen
     from bs4 import BeautifulSoup
     import requests
     import re
     import string

     #----------------
     # Forecast
     from statsmodels.tsa.seasonal import seasonal_decompose
     from pmdarima.arima import auto_arima
     import statsmodels.api as sm

     #----------------
     # Verschiedenes
     from plotly.offline import download_plotlyjs, init_notebook_mode, plot, iplot
     init_notebook_mode(connected=True)
     import chart_studio.plotly as py
     import plotly.graph_objs as go
     import matplotlib.pyplot as plt
     %matplotlib inline
     import matplotlib.patches as mpatches
     import numpy as np
     import pandas as pd
     import datetime
     from sklearn.metrics import mean_squared_error
     from sklearn.metrics import r2_score
     from IPython.core.display import display, HTML
```

1.1.2 Optikeinstellungen

Anschließend werden Einstellungen definiert, die die Formatierung der Ausgaben betreffen. Hierfür wird das Modul `operator` genutzt. Außerdem wird die Breite des im Folgenden genutzten DataFrames erhöht und die Größe der Grafiken modifiziert, welche später angezeigt werden sollen.

```
[2]: %%javascript
     IPython.OutputArea.auto_scroll_threshold = 9999;
```

```
<IPython.core.display.Javascript object>
```

```
[3]: display(HTML("<style>.container { width:100% !important; }</style>"))
     pd.set_option('display.width', 350)
     plt.rcParams['figure.figsize'] = (36, 12) # macht die Plots größer
```

```
<IPython.core.display.HTML object>
```

1.2 Datenbeschaffung und Manipulation

1.2.1 Web-Scraping historischer Daten von Statista

Mittels Web-Scraping werden historische Daten zu Umsätzen verschiedener Unternehmen von Statista gedownloaded und aufbereitet, bevor diese in zwei separaten Listen gespeichert werden.

```
[4]: #---------------------------------------
     # Datensätze
     #----------------
     # Amazon
     #url = 'https://www.statista.com/statistics/273963/quarterly-revenue-of-amazoncom/'
     #----------------
     # Apple
     #url = 'https://www.statista.com/statistics/263427/apples-net-income-since-first-quarter-2005/'
     #----------------
     # Alibaba
     url = 'https://www.statista.com/statistics/323046/alibaba-quarterly-group-revenue/'

     #---------------------------------------
     # Daten beschaffen und Tabellen extrahieren
     html = requests.get(url)
     soup = BeautifulSoup(html.text, 'lxml')

     chart = soup.find("tbody")
     children = chart.find_all("tr")

     #---------------------------------------
     # Extrahierte Tabellen bereinigen
     data = []
     for tag in children:
         data_tuple = (tag.text[:6],tag.text[6:])
         data.append(data_tuple)

     quartals, revenues = [], []
     for i in range(0, len(data)):
         x = data[i][0]
         y = data[i][1]
         quartal = x.replace(' ', '')
         y = y.replace(',', '.')
         revenue = float(y)
         quartals.append(quartal)
         revenues.append(revenue)

     #---------------------------------------
     # Reihenfolge der extrahierten Daten umkehren und ausgeben

     quartals = quartals[::-1]
     revenues = revenues[::-1]
     print(quartals)
     print(revenues)
```

```
["Q4'13", "Q1'14", "Q2'14", "Q3'14", "Q4'14", "Q1'15", "Q2'15", "Q3'15",
"Q4'15", "Q1'16", "Q2'16", "Q3'16", "Q4'16", "Q1'17", "Q2'17", "Q3'17", "Q4'17",
"Q1'18", "Q2'18", "Q3'18", "Q4'18", "Q1'19", "Q2'19", "Q3'19", "Q4'19"]
[18.745, 12.031, 15.771, 16.829, 26.179, 17.425, 20.245, 22.171, 34.543, 24.184,
32.154, 34.292, 53.248, 38.579, 50.184, 55.122, 83.028, 61.932, 80.92, 85.148,
117.278, 93.498, 114.924, 119.017, 161.456]
```

1.2.2 Weitere Modifikationen

Die von der Website extrahierten Quartalskennzeichnungen in ein für datime interpretierbares Format überführt.

```
[5]: #---------------------------------------
     # Quartale in ein für datime interpretierbares Format überführen
     quartals_new = []
     for i in quartals:
         x = '20' + str(i[3:])
         y = i[:2]
         z = str(x) + '-' + str(y)
         quartals_new.append(z)

     quartals_new[:5]
```

```
[5]: ['2013-Q4', '2014-Q1', '2014-Q2', '2014-Q3', '2014-Q4']
```

1.3 Erstellung eines DataFrames und Visualisierung

1.3.1 Generierung des DataFrames

Es wird ein DataFrame erzeugt, welcher die Umsätze zum jeweiligen Quartal enthält.

```
[6]: #---------------------------------------
     # DataFrame mit bereinigten Daten erzeugen
     original_data = pd.DataFrame({'Periode':quartals_new, 'Umsatz':revenues})
     original_data['Periode'] = pd.to_datetime(original_data['Periode'].str.replace(r'(Q\d) (\d+)', r'\2-\1'), errors='coerce')
     original_data.tail()
```

```
[6]:       Periode   Umsatz
     20 2018-10-01  117.278
     21 2019-01-01   93.498
     22 2019-04-01  114.924
     23 2019-07-01  119.017
     24 2019-10-01  161.456
```

1.3.2 Visualisierung der Daten

Der DataFrame wird visualisiert.

```
[7]: #---------------------------------------
     # Plotten der Daten
     original_data.Umsatz.plot(figsize=(12,8), title='Revenues Apple', fontsize=20)
```

```
[7]: <matplotlib.axes._subplots.AxesSubplot at 0x2538d4fad88>
```

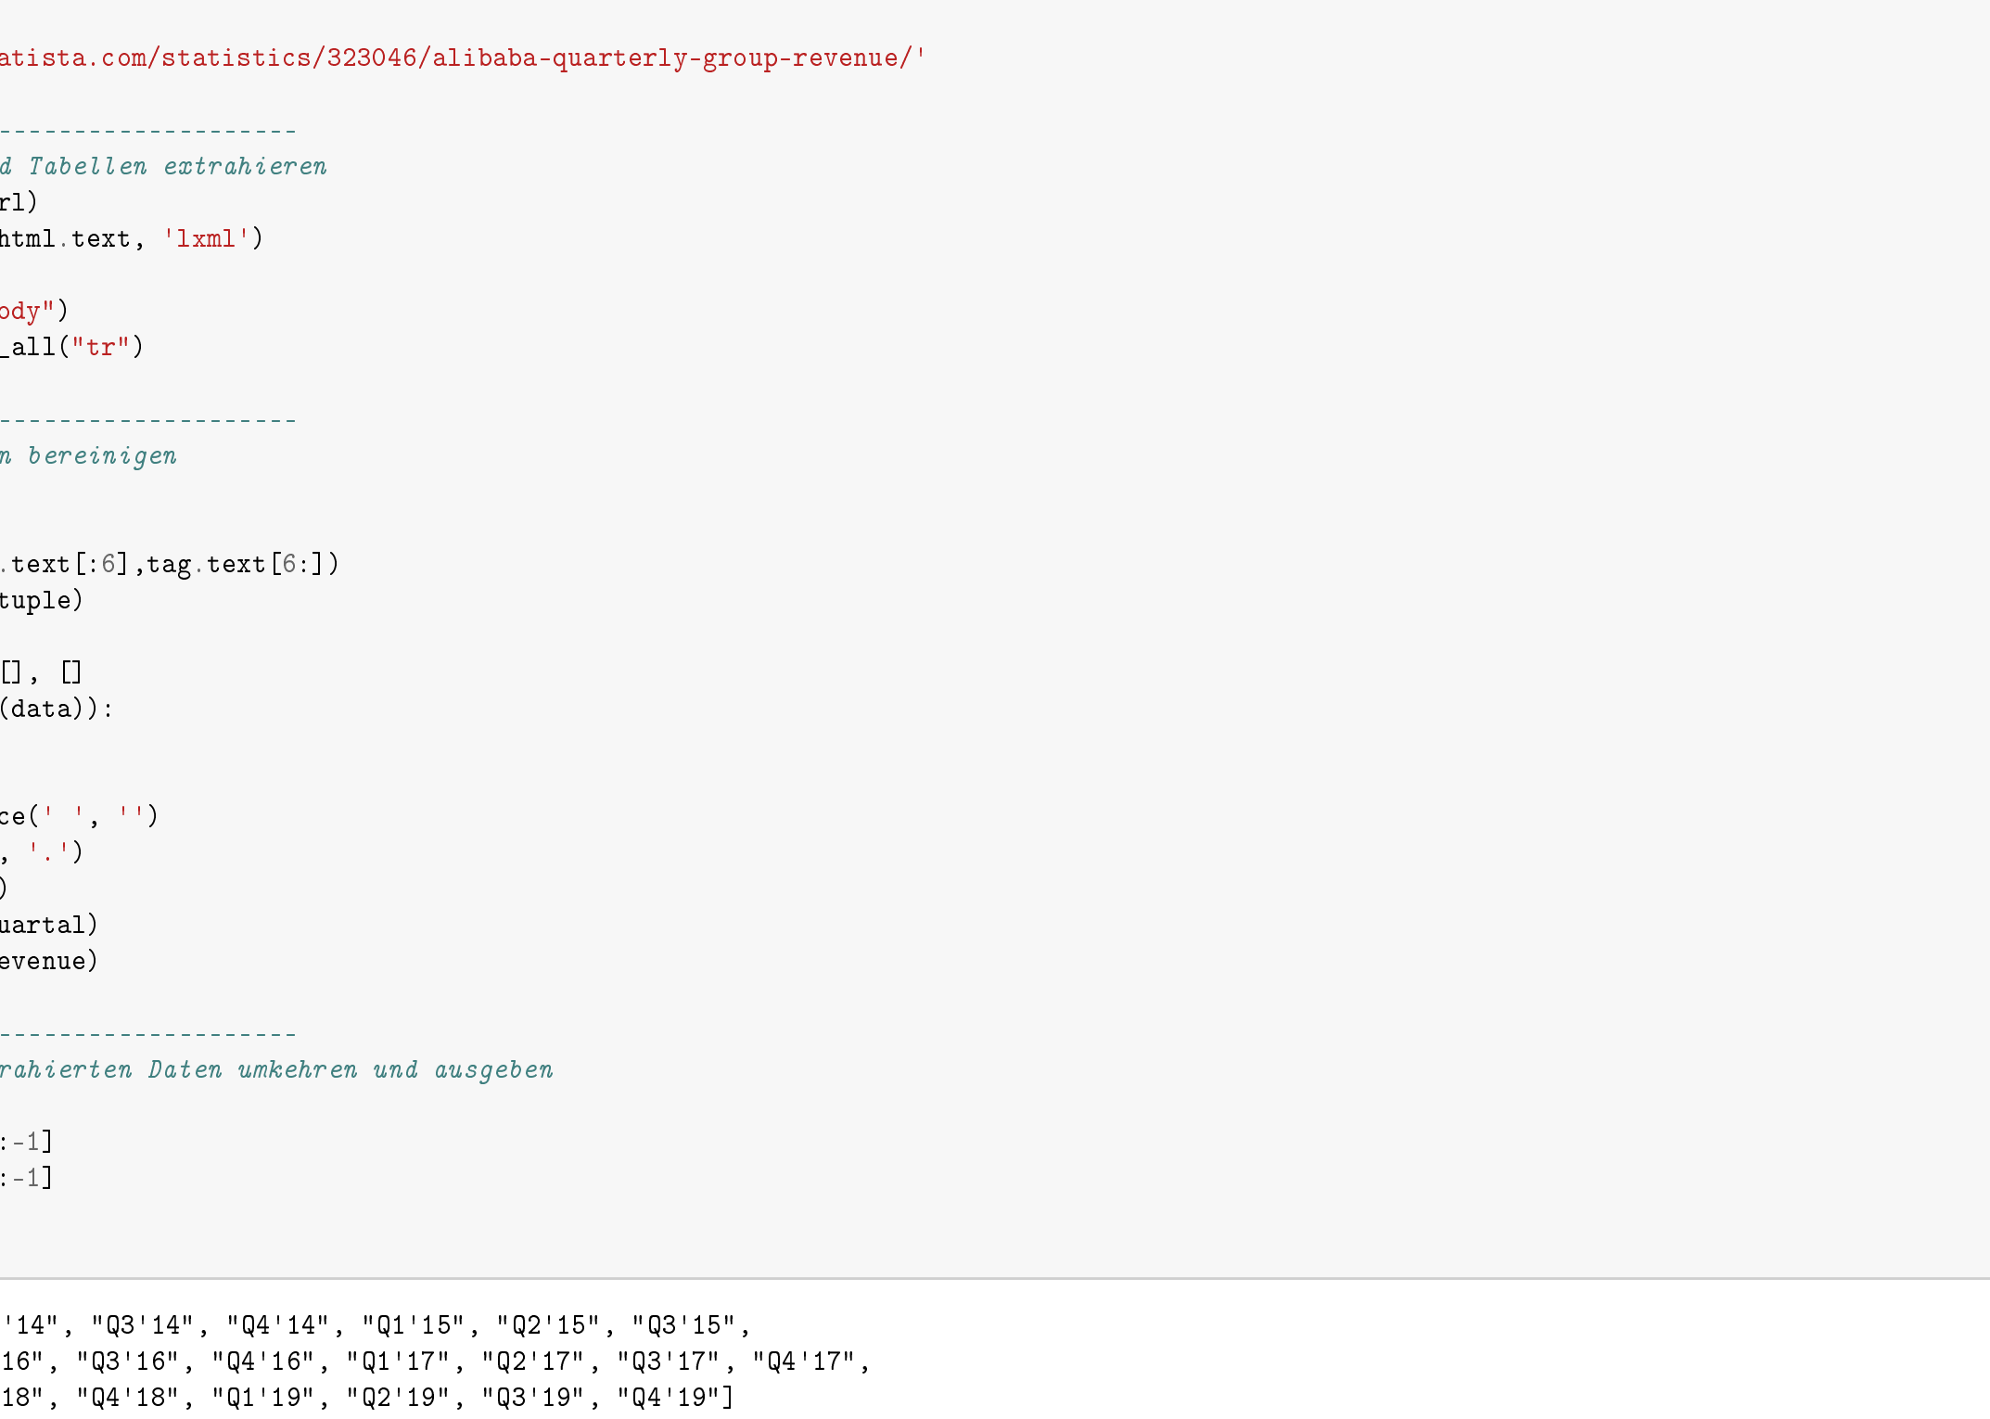

1.4 Datenanalyse und Vorbereitung für die Prognose

1.4.1 Datenanalyse - Komponentenanalyse

Die Zeitreihe wird in ihre einzelne Komponenten zerlegt, d.h. es werden Trend, Saisonalität und Residuum aus der beobachteten Zeitreihe extrahiert und separat visualisiert.

```
[8]: #---------------------------------------
     # Dekomposion der Daten und plotten
     decomposition = seasonal_decompose(original_data.Umsatz, freq=4)
     fig = plt.figure()
     fig = decomposition.plot()
     fig.set_size_inches(15, 8)
```

```
<Figure size 2592x864 with 0 Axes>
```

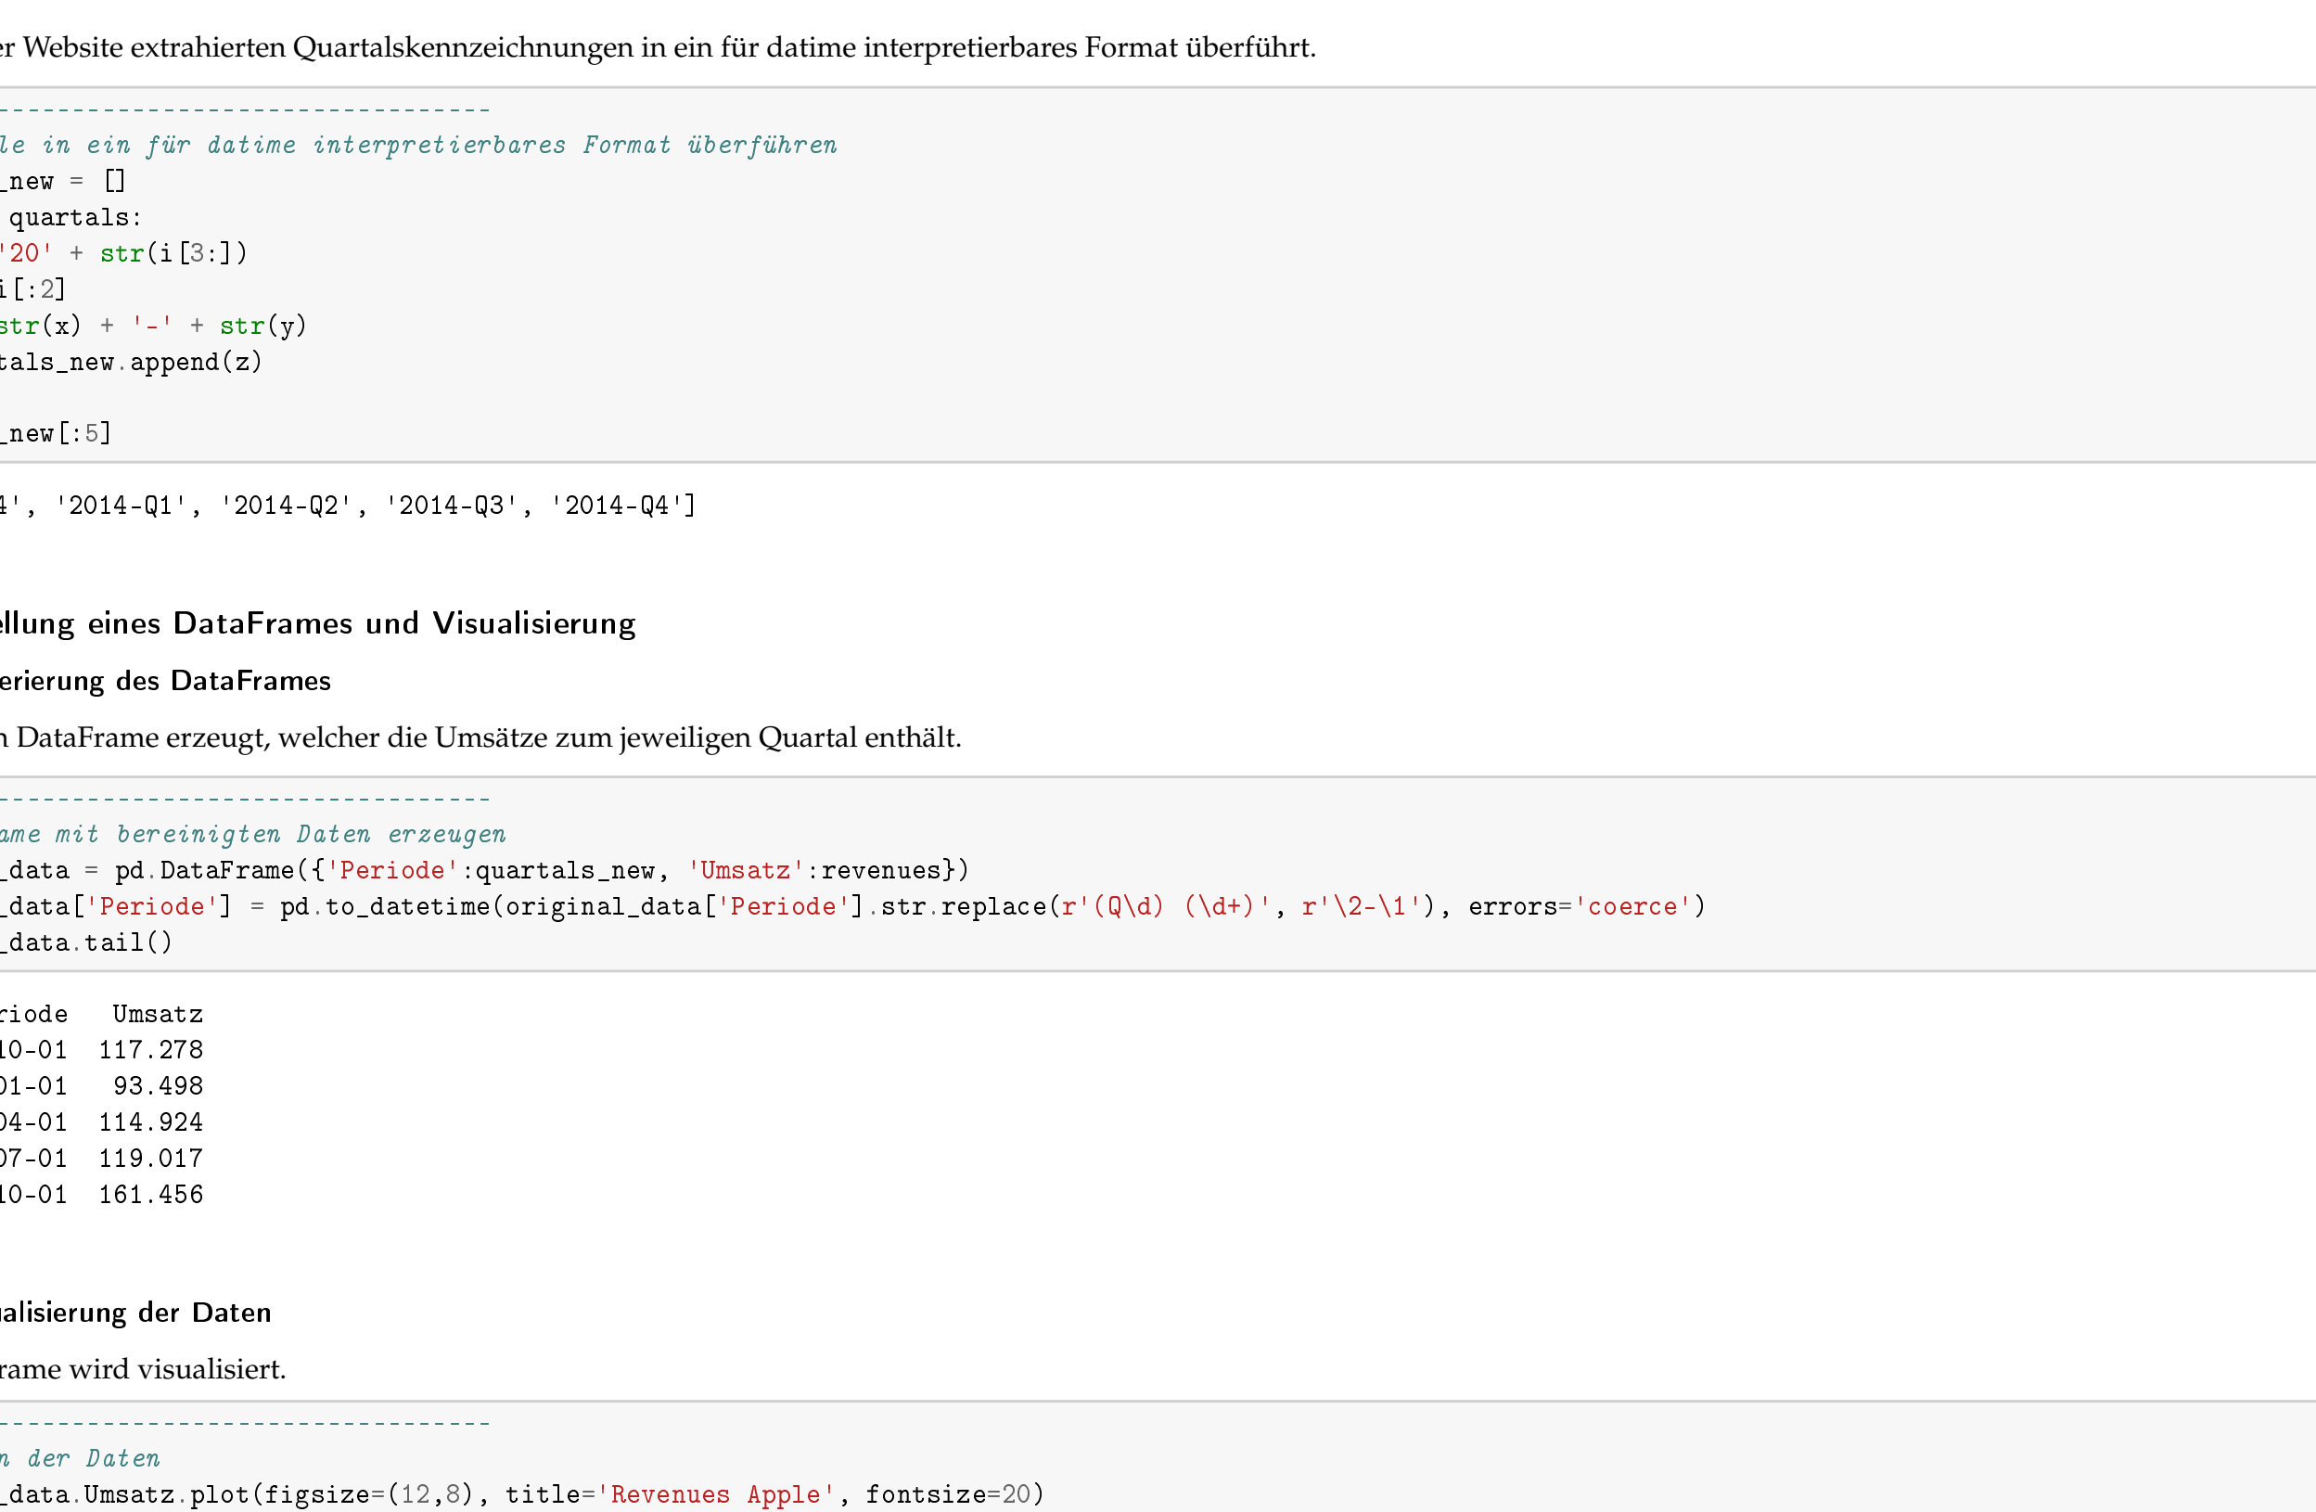

1.4.2 Datenanalyse - Stationarität

Die beobachtete Zeitreihe wird auf Stationarität hinsichtlich Erwartungswert und Standardabweichung untersucht. Um eine Prognose vornehmen zu können müssen stationäre Daten vorliegen. Dies wird später durch die "Auto-SARIMA-Funktion automatisch sichergestellt. Hinweis: Die Komponenten sind (noch) nicht stationär.

```
[9]: #---------------------------------------
     # Berechnung gleitender Durchschnitt sowie gleitende Standardabweichung
     rolmean = original_data.rolling(window=4).mean()
     rolstd = original_data.rolling(window=4).std()

     #---------------------------------------
     # Plotten
     orig = plt.plot(original_data.Umsatz, color='blue', label='Original')
     mean = plt.plot(rolmean, color='orange', label='mean')
     std = plt.plot(rolstd, color='red', label='std')
     plt.legend(loc='best')
     plt.title('Rolling Mean and STD')
     plt.show()
```

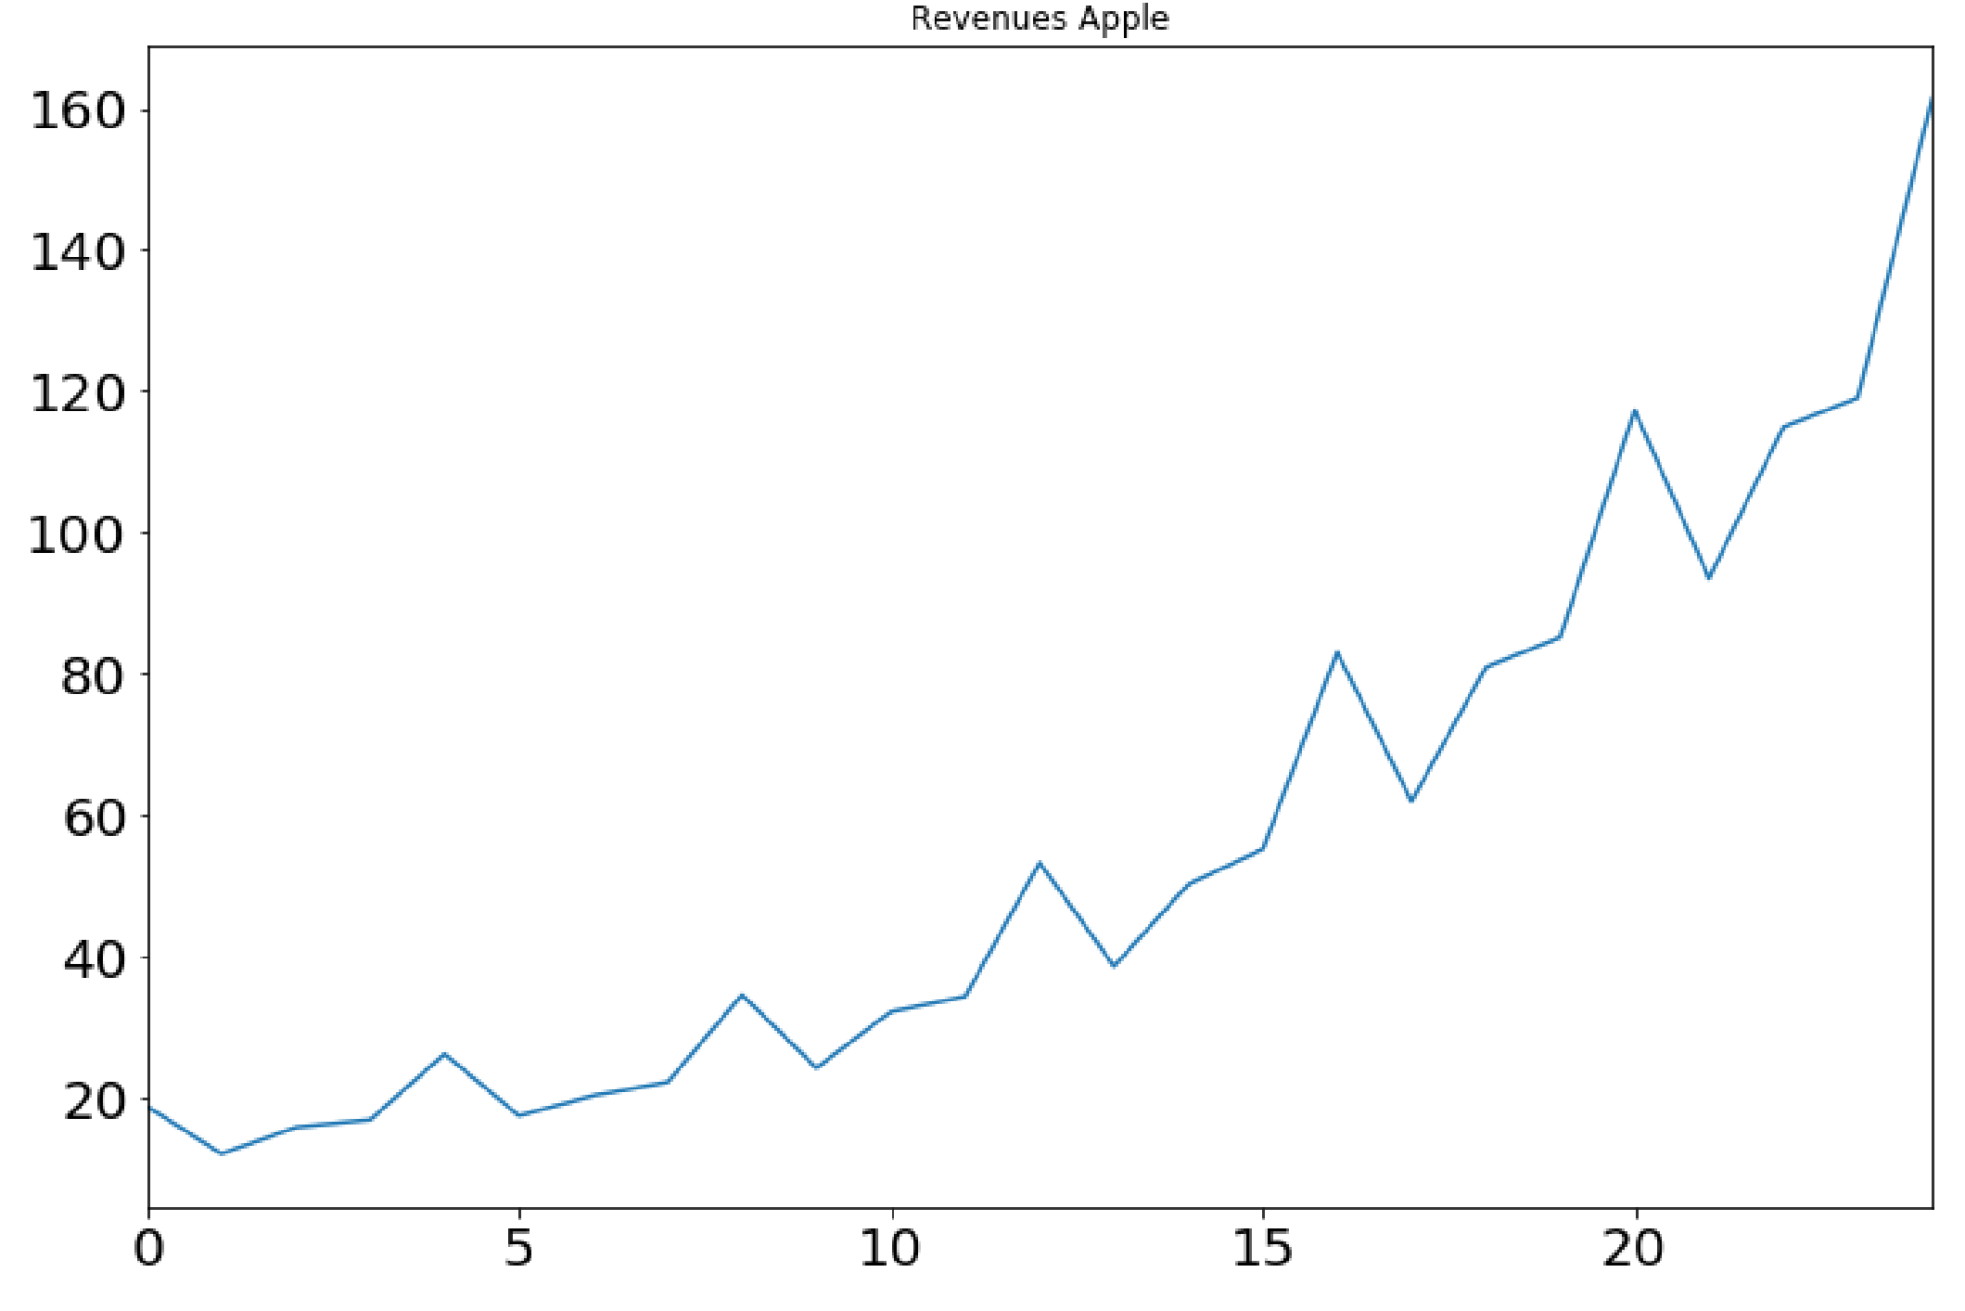

1.4.3 Vorbereitung zur Prognose - Erstellung eines Test- und eines Trainingsdatensatzes

Der ursprüngliche Datensatz wird in einen Test- und einen Traingsdatensatz zerlegt. Ersterer dient dazu die Güte des Modells beurteilen zu können (grafisch), während letzterer zum Traing des modells verwendet wird.

Traingsdatensatz

```
[10]: #---------------------------------------
      # Trainings-Datensatz
      train_df = original_data.copy(deep=True)
      train_df.drop(train_df.tail(6).index,inplace=True)
      train_df.tail(6)
```

```
[10]:       Periode  Umsatz
      13 2017-01-01  38.579
      14 2017-04-01  50.184
      15 2017-07-01  55.122
      16 2017-10-01  83.028
      17 2018-01-01  61.932
      18 2018-04-01  80.920
```

Testdatensatz

```
[11]: #---------------------------------------
      # Test-Datensatz
      test_df = original_data.tail(6)
      test_df
```

```
[11]:       Periode   Umsatz
      19 2018-07-01   85.148
      20 2018-10-01  117.278
      21 2019-01-01   93.498
      22 2019-04-01  114.924
      23 2019-07-01  119.017
      24 2019-10-01  161.456
```

1.5 Prognose

1.5.1 Anwendung des (Auto-)SARIMA-Modells

Es erfolgt eine automatisierte Suche nach bestem Modell bzw. den besten Hyperparametern des SARIMA-Modells anhand des AIC.

```
[12]: decomposition = auto_arima(train_df.Umsatz, start_p=1, start_q=1,
                                 max_p=5, max_q=5, max_d=5, m=4,
                                 start_P=0, seasonal=True,
                                 d=None, D=None, trace=True,
                                 error_action='ignore',
                                 information_criterion='aic',
                                 n_jobs=10, scoring='mse',
                                 suppress_warnings=True,
                                 stepwise=True)
```

```
C:\Users\Pablo\Anaconda3\lib\site-packages\pmdarima\arima\auto.py:234:
UserWarning:

stepwise model cannot be fit in parallel (n_jobs=1). Falling back to stepwise
parameter search.


Fit ARIMA: order=(1, 1, 1) seasonal_order=(0, 0, 1, 4); AIC=129.703,
BIC=134.155, Fit time=0.110 seconds
Fit ARIMA: order=(0, 1, 0) seasonal_order=(0, 0, 0, 4); AIC=145.055,
BIC=146.836, Fit time=0.004 seconds
Fit ARIMA: order=(1, 1, 0) seasonal_order=(1, 0, 0, 4); AIC=117.705,
BIC=121.267, Fit time=0.043 seconds
Fit ARIMA: order=(0, 1, 1) seasonal_order=(0, 0, 1, 4); AIC=130.005,
BIC=133.567, Fit time=0.090 seconds
Fit ARIMA: order=(1, 1, 0) seasonal_order=(0, 0, 0, 4); AIC=136.970,
BIC=139.641, Fit time=0.014 seconds
Fit ARIMA: order=(1, 1, 0) seasonal_order=(2, 0, 0, 4); AIC=113.647,
BIC=118.099, Fit time=0.088 seconds
Fit ARIMA: order=(1, 1, 0) seasonal_order=(2, 0, 1, 4); AIC=115.646,
BIC=120.988, Fit time=0.183 seconds
Fit ARIMA: order=(0, 1, 0) seasonal_order=(2, 0, 0, 4); AIC=115.545,
BIC=119.106, Fit time=0.058 seconds
Fit ARIMA: order=(2, 1, 0) seasonal_order=(2, 0, 0, 4); AIC=115.472,
BIC=120.814, Fit time=0.143 seconds
Fit ARIMA: order=(1, 1, 1) seasonal_order=(2, 0, 0, 4); AIC=115.327,
BIC=120.669, Fit time=0.157 seconds
Fit ARIMA: order=(2, 1, 1) seasonal_order=(2, 0, 0, 4); AIC=116.850,
BIC=123.082, Fit time=0.233 seconds
Total fit time: 1.131 seconds
```

1.5.2 Ausgabe Informationskriterium

Ausgabe desjenigen Informationskriteriums, welches sich nach dem Modelllauf als bestmöglich erweist.

```
[13]: decomposition.aic()
```

```
[13]: 113.64688894445932
```

1.5.3 Anwendung des Modells mit dem besten Fit auf den Trainingsdatensatz

```
[14]: mod = sm.tsa.statespace.SARIMAX(train_df.Umsatz,
                                      order=(1, 1, 0),
                                      seasonal_order=(2, 0, 0, 4),
                                      enforce_stationarity=True,
                                      enforce_invertibility=True)
      decomposition = mod.fit()
      decomposition.summary()
```

```
C:\Users\Pablo\Anaconda3\lib\site-
packages\statsmodels\tsa\statespace\sarimax.py:981: UserWarning:

Non-stationary starting seasonal autoregressive Using zeros as starting
parameters.
```

```
[14]: <class 'statsmodels.iolib.summary.Summary'>
      """
                                 Statespace Model Results
      ==============================================================================
      =========
      Dep. Variable:                            Umsatz   No. Observations:
      19
      Model:             SARIMAX(1, 1, 0)x(2, 0, 0, 4)   Log Likelihood
      -52.818
      Date:                           Tue, 14 Apr 2020   AIC
      113.636
      Time:                                   10:40:30   BIC
      117.197
      Sample:                                        0   HQIC
      114.127
                                                  - 19
      Covariance Type:                             opg
      ==============================================================================
                       coef    std err          z      P>|z|      [0.025      0.975]
      ------------------------------------------------------------------------------
      ar.L1         -0.3896      0.276     -1.411      0.158      -0.931       0.152
      ar.S.L4        1.5954      0.315      5.065      0.000       0.978       2.213
      ar.S.L8       -0.6489      0.382     -1.699      0.089      -1.397       0.100
      sigma2         8.6975      4.496      1.935      0.053      -0.114      17.509
      ==============================================================================
      ===
      Ljung-Box (Q):                        nan   Jarque-Bera (JB):
      1.48
      Prob(Q):                              nan   Prob(JB):
      0.48
      Heteroskedasticity (H):              9.94   Skew:
      0.57
      Prob(H) (two-sided):                 0.01   Kurtosis:
      2.18
      ==============================================================================
      ===

      Warnings:
      [1] Covariance matrix calculated using the outer product of gradients (complex-
      step).
      """
```

1.5.4 Ermittlung des Forcast und Visualisierung

Ermittlung Forcast Die nächsten sechs an den Traingsdatensatz anknüpfenden Perioden werden prognostiziert.

```
[15]: forecast = decomposition.forecast(6)
```

Visualisierung Forecast v.s. Testdatensatz (historische Daten)

```
[16]: #---------------------------------------
      # Forecast DataFrame vs Test-DataFrame
      yActual = test_df['Umsatz'].values.tolist()
      yPredicted = forecast.head(6).values.tolist()
      periode = test_df.Periode
      #---------------------------------------
      # Ploten
      plt.plot(periode,yActual, color='red') # Rot
      plt.plot(periode,yPredicted, color='green') # Grün
      green_patch = mpatches.Patch(color='green', label='Forecast')
      red_patch = mpatches.Patch(color='red', label='Historisch')
      plt.legend(handles=[green_patch, red_patch])
      plt.title("Forecasted Value vs Actuals")
      plt.show()
```

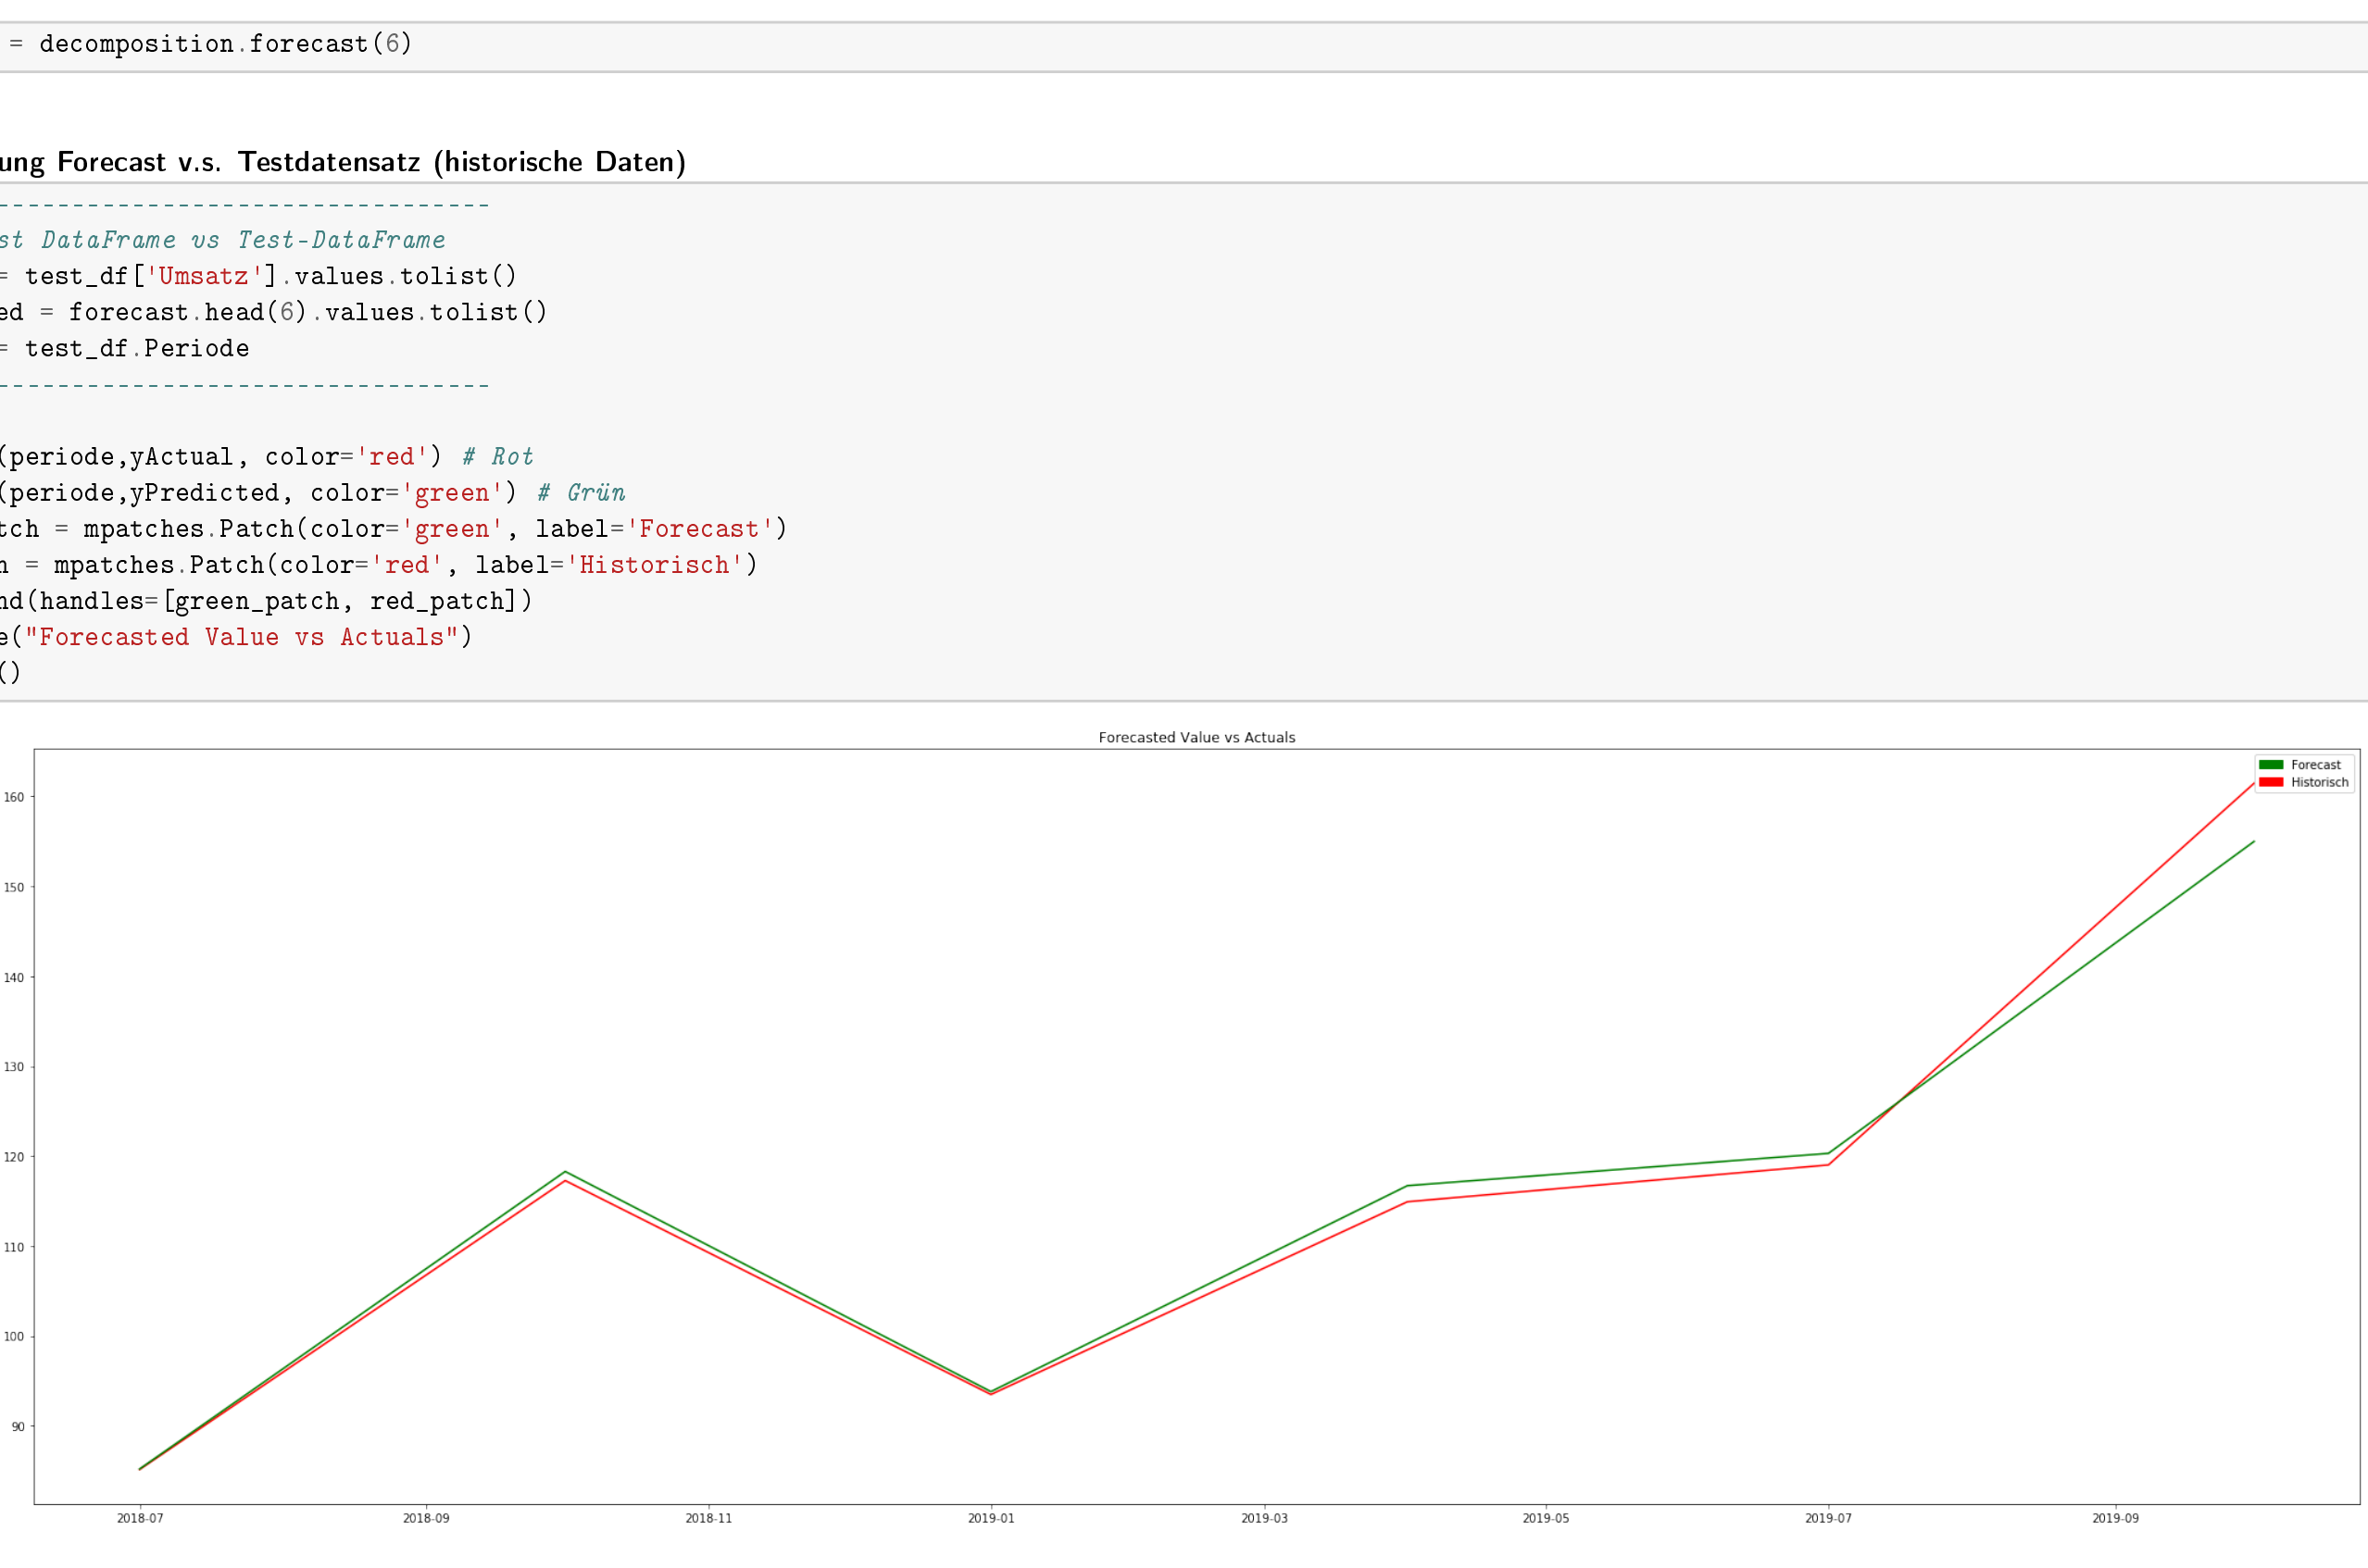

Darstellung als DataFrame

```
[17]: compare_df = pd.DataFrame()
      compare_df['Period'] = test_df.Periode
      compare_df['Umsatz_original'] = yActual# np.exp(yActual)
      compare_df['Umsatz_Forecast'] = yPredicted #np.exp(yPredicted)
      compare_df['PctChg'] = abs(round(((compare_df.Umsatz_original - compare_df.Umsatz_Forecast) / compare_df.Umsatz_original * 100), 2))
      compare_df
```

```
[17]:        Period  Umsatz_original  Umsatz_Forecast  PctChg
      19 2018-07-01           85.148        85.211994    0.08
      20 2018-10-01          117.278       118.290386    0.86
      21 2019-01-01           93.498        93.817991    0.34
      22 2019-04-01          114.924       116.711655    1.56
      23 2019-07-01          119.017       120.304466    1.08
      24 2019-10-01          161.456       154.990847    4.00
```

1.5.5 Fehlermetriken

Im Mittel liegt das Modul um 1,32% neben den tatsächlichen Beobachtungen

```
[18]: compare_df.PctChg.mean()
```

```
[18]: 1.32
```

1.5.6 Mean Squared Error

Der MSE nimmt im Vergleich zu Modellen mit anderen Parametern einen recht kleinen Wert an, sodass das gewählte Modell recht gut performt.

```
[19]: mean_squared_error(compare_df['Umsatz_original'], compare_df['Umsatz_Forecast'])
```

```
[19]: 7.9638162771338985
```

1.5.7 Bestimmtheitsmaß

Das bestimmtheitsmaß nimmt einen recht hohen wert an. Das beweutet, dass das Modell relativ viel der Varianz im Testdatensatz erklären kann und damit für die Prognose gut geeignet ist.

```
[20]: r2_score(compare_df['Umsatz_original'], compare_df['Umsatz_Forecast'])
```

```
[20]: 0.9864740310635753
```

1.6 Prognose für die nächsten sechs Quartale

1.6.1 Forecast erzeugen und in DataFrame darstellen

Die nächsten sechs Quartale werden prognostiziert und visualisiert.

```
[21]: #---------------------------------------
      # Forecast
      periods_forcast = range(1,6)
      x = forecast = decomposition.forecast(11)
      #---------------------------------------
      # Erstellung DataFrame
      forecast = pd.DataFrame({'Periode':periods_forcast, 'Umsatz': x[6:]})
      forecast.head(6)
```

```
[21]:     Periode      Umsatz
      25        1  129.627898
      26        2  153.835216
      27        3  156.781178
      28        4  190.657565
      29        5  166.072112
```

```
[22]: original_data['Umsatz'] = original_data['Umsatz']
      original_data = original_data.append(forecast[1:], sort=True)
      _ = original_data.drop(['Periode'], axis=1)
```

1.6.2 Visualisierung

```
[23]: original_data['Umsatz'].plot()
```

```
[23]: <matplotlib.axes._subplots.AxesSubplot at 0x2538ede2908>
```